

**Implementación de un esquema de reconocimiento de defectos en café
almendra, a través de visión computacional, para evaluar la calidad física de
granos, en Tecnicafé – Cajibío Cauca**



Universidad
del Cauca

Yamuna Devi Mena Ramírez

Universidad del Cauca

Facultad de Ciencias Naturales, Exactas y de la educación

Departamento de Física

Popayán, Colombia

2023

**Implementación de un esquema de reconocimiento de defectos en café
almendra, a través de visión computacional, para evaluar la calidad física de
granos, en Tecnicafé – Cajibío Cauca**

Yamuna Devi Mena Ramírez

Trabajo de grado, modalidad pasantía, presentado como requisito parcial para optar al título de
Ingeniera Física

Director:

Ing. Edgar Leonairo Pencue Fierro

Profesor Departamento de Física - Universidad del Cauca

Asesora:

Ing. Jasmin Medina

Coordinadora Tecnológica. – Tecnicafé

Universidad del Cauca

Facultad de Ciencias Naturales, Exactas y de la educación

Departamento de Física

Popayán, Colombia

2023

Nota de Aceptación

Aprobado por el comité de grado en cumplimiento de los requisitos exigidos por la Universidad del Cauca para optar al título de Ingeniera Física.

Ing. Edgar Leonairo Pencue Fierro

DIRECTOR

MSc. Jorge Washington Coronel García

JURADO

MSc. Carlos Felipe Ordoñez Urbano

JURADO

Fecha de sustentación: 20 de abril de 2023

Agradecimientos

Agradezco a Dios, mi familia, mis amigos y a los profesores que me brindaron su apoyo.

Resumen

El proceso de reconocimiento y clasificación de defectos en el café es fundamental tanto desde el punto de vista productivo como comercial. Este proceso determina la calidad del producto, establece las bases necesarias para su clasificación en el mercado y, al mismo tiempo, sirve como un indicador clave de buenas prácticas en los procesos de cultivo y beneficio del café. Dicha clasificación es propensa a errores, debido a que es un procedimiento que se realiza de manera visual y es subjetivo al evaluador-observador. Por esta razón, el objetivo del presente trabajo es diseñar e implementar un esquema de reconocimiento de defectos de café en almendra mediante el uso de visión computacional en el parque tecnológico de innovación del café -Tecnicafé.

En el proceso de clasificación de los granos de café se consideraron 11 tipos de defectos de acuerdo con las normas establecidas por la *Specialty Coffee Association of America*. Se utilizaron 817 descriptores para caracterizar la forma, color y textura de los granos y se evaluaron tres técnicas de clasificación: *Random Forest*, *K-Nearest Neighbor* y *Support Vector Machine*. Después de realizar la validación y evaluación de los clasificadores, se determinó que el modelo *Random Forest* proporcionó los mejores resultados. Posteriormente, se empleó un algoritmo de recursividad para reducir el número de descriptores a 323 y se evaluó nuevamente el modelo con esta cantidad. Como resultado, se logró alcanzar un *accuracy* del 94.18%, lo que muestra un valor óptimo de exactitud en la clasificación de los granos de café.

Contenido

Introducción	11
Institución Colaboradora: Parque Tecnológico de Innovación del Café	13
Definición del Problema	14
Objetivos	15
Objetivo general.....	15
Objetivos Específicos.....	15
Marco Teórico.....	16
Marco Conceptual	16
Calidad del Café.....	16
Visión Computacional	25
Machine Learning	32
Validación y Evaluación de la Clasificación	36
Marco Referencial.....	39
Trabajos Anteriores.....	40
Metodología	44
Selección de los Granos	44
Captura de Imágenes.....	46
Preprocesamiento	48

Recorte de Imágenes	48
Eliminación de Ruido	51
Segmentación	51
Extracción de Descriptores	52
Descriptores de Color	52
Descriptores de Forma y Tamaño	57
Descriptores de Textura	59
Clasificación	60
Evaluación de la clasificación	60
Depuración y Selección de Descriptores	60
Resultados y Análisis	62
Selección del Mejor Modelo	62
Eliminación y Selección de Descriptores	66
Resultados Finales	69
Conclusiones	77
Bibliografía	79

Lista de Tablas

Tabla 2.1 Equivalencias de los defectos (<i>SCA</i>).....	17
Tabla 4.1 Métricas de desempeño para <i>SVM</i>	56
Tabla 4.2 Métricas de desempeño para <i>KNN</i>	56
Tabla 4.3 Métricas de desempeño para <i>RF</i>	57
Tabla 4.4 Métricas de desempeño para <i>RF</i> con 323 descriptores.....	62
Tabla 4.5 Promedio de las métricas según el número de descriptores.....	63
Tabla 4.6 Métricas de desempeño.....	64
Tabla 4.7 Clasificación de los granos por categoría.....	64

Lista de Figuras

Figura 2.1 Café almendra sano.....	20
Figura 2.2 Granos negros.....	20
Figura 2.3 Granos agrios.....	21
Figura 2.4 Granos cereza seca.....	21
Figura 2.5 Granos con hongos.....	22
Figura 2.6 Granos con broca	22
Figura 2.7 Granos pergaminos.....	23
Figura 2.8 Granos flotadores	23
Figura 2.9 Granos inmaduros.....	24
Figura 2.10 Granos arrugados.....	24
Figura 2.11 Granos partidos/ mordidos/ cortados.....	25
Figura 2.12 Gráfico espacio RGB.....	26
Figura 2.13 Gráfico del espacio HSV.....	27
Figura 2.14 Gráfico del espacio YCbCr.....	28
Figura 2.15 Gráfico del espacio XYZ.....	29
Figura 2.16 Histograma de color.....	30
Figura 2.17 Matriz de confusión 2x2.....	37
Figura 3.1 Esquema para la clasificación de defectos.....	44
Figura 3.2 Montaje para la captura de imágenes.....	47
Figura 3.3 Fotografía ejemplo de las muestras.....	47
Figura 3.4 Imagen segmentada.....	48

Figura 3.5 Imagen segmentada sin presencia de ruido.....	49
Figura 3.6 Rectángulos delimitadores para cada grano.....	50
Figura 3.7 Imágenes recortadas para cada grano.....	50
Figura 3.8 (a) Grano arrugado sin filtro gaussiano, (b) Grano arrugado.....	51
Figura 3.9 (a) Imagen con filtro Gaussiano (b) Máscara de la imagen.....	52
Figura 3.10 Planos del espacio RGB	53
Figura 3.11 Planos del espacio HSV.....	53
Figura 3.12 Planos del espacio XYZ	54
Figura 3.13 Planos del espacio YCbCr.....	54
Figura 3.14 Histograma de un grano con defecto tipo vinagre.....	56
Figura 3.15 Contorno y área de un grano de café.....	58
Figura 4.1 Gráfica del accuracy para los modelos SVM, KNN, RF.....	63
Figura 4.2 Gráfica de la precision para los modelos SVM, KNN, RF.....	64
Figura 4.3 Gráfica del recall para los modelos SVM, KNN, RF.....	64
Figura 4.4 Gráfica del F1-Score para los modelos SVM, KNN, RF.....	65
Figura 4.5 Gráfica de eliminación recursiva de descriptores.....	67
Figura 4.6 Zoom de gráfica de eliminación recursiva de descriptores.....	68
Figura 4.7 Matriz de confusión.....	71

Introducción

El café es uno de los productos más vendidos y consumidos, del que se estima que existen en el mundo más de 20 millones de productores ubicados en 50 países. Se identifica a Colombia como uno de los países con mayor producción y comercialización de café debido a su excelente calidad, ubicándose como uno de los productos de exportación más importantes para nuestro país. La cadena productiva del café involucra a 590 municipios, beneficiando económicamente a miles de trabajadores directos e indirectos, incluyendo tanto a grandes como pequeños productores. Como resultado, aproximadamente 536000 familias obtienen su sustento de manera directa gracias a esta actividad. Además, se evidencia que la producción y comercialización del café ha generado un gran impacto económico, social y cultural en el país, convirtiéndose en un factor importante para la generación de divisas y empleos, especialmente en las zonas rurales. (Puerta, 2015; Specialty Coffee Association, 2019; Pérez, 2009)

Bajo esta perspectiva, es necesario hablar sobre la contribución de la ingeniería en el mejoramiento de los diferentes procesos dentro de la industria del café. En el transcurso del tiempo, los procedimientos agrícolas se han ido mejorando gracias al aporte ingenieril y tecnológico, formando procesos más sostenibles y eficientes. Siendo la caficultura una de las industrias beneficiadas que evidencian mejoramientos casi en toda su cadena productiva, desde la elaboración de germinadores hasta la recolección o cosecha.

Por esta razón, en colaboración con Tecnicafé y la Universidad del Cauca, se llevó a cabo un trabajo enfocado en apoyar el mejoramiento de la calidad final del producto, y reducir el tiempo de detección de defectos en el café almendra. La importancia de esta fase del proceso, radica en que el cambio de una clasificación manual a una semiautomática y más rápida, tiene ventajas significativas en la optimización del procedimiento y en la mejora de la identificación de defectos.

En este sentido, este trabajo se ha dividido en las siguientes secciones:

- Marco teórico: En esta sección se presenta una revisión actualizada de la literatura relevante con relación a los conceptos, teorías y técnicas empleadas en la clasificación de granos de café, haciendo hincapié en la visión computacional y en la teoría de la calidad del café.
- Metodología: En esta sección se exponen los procedimientos y herramientas utilizados para abordar la clasificación de los defectos. Se describen las técnicas, algoritmos y herramientas computacionales utilizadas para el análisis y procesamiento de imágenes.
- Resultados y análisis: En la sección de Resultados y Análisis, se presentan los resultados obtenidos tras la evaluación del rendimiento del sistema de clasificación. Además, se realiza un análisis de dichos resultados en función de algunas métricas de desempeño, y se discuten tanto las limitaciones como los beneficios que se pueden obtener del sistema.
- Conclusiones: En esta sección se resumen las principales observaciones y resultados, obtenidos durante todo el proceso de clasificación de defectos, así como destacar la relevancia y contribución del trabajo a la disciplina de la visión computacional en la clasificación de granos de café.

Con esta estructura, se busca proporcionar una visión completa y detallada del proceso seguido, desde el marco teórico hasta las conclusiones, con el objetivo de presentar una metodología rigurosa y aportar conocimientos útiles al campo de la visión computacional en la industria del café.

Institución Colaboradora: Parque Tecnológico de Innovación del Café

Es una organización sin ánimo de lucro, ubicada en el municipio de Cajibío-Cauca, al sur de Colombia, está enfocada en la gestión del conocimiento para la innovación abierta y colaborativa que, a partir de la vigilancia tecnológica e inteligencia competitiva, fomenta el emprendimiento y la innovación empresarial en el aprovechamiento sustentable de los recursos del ecosistema cafetero. facilitando la construcción efectiva de cadenas de valor en modelos de negocios inclusivos, equitativos, transparentes y justos. (Hoyos García, 2022)

Enfoques Estratégicos:**a) Ciencia**

Apoyan la generación de nuevo conocimiento a partir de la articulación con los actores vinculados a la cadena de valor de café y sus actividades conexas

b) Tecnología

Promueven el aprovechamiento práctico del conocimiento en el desarrollo y la comercialización de tecnologías que fortalezcan la productividad y competitividad del sector cafetero.

c) Innovación

Emprenden la creación de bienes y servicios innovadores con alto valor económico y su eficaz inserción en los mercados.

Definición del Problema

En Colombia, por lo general, se hacen dos cosechas de café al año, denominadas cosecha principal y mitaca, con una producción aproximada de 14.1 millones de sacos de 60 kg por año. En el transcurso de algunas semanas, cafeteros de todo el país deben adecuar su café y pasarlo por diferentes procesos de evaluación para proceder a su posible exportación, congestionando entidades encargadas de realizar el análisis de la calidad física del café y, más precisamente, el proceso de detección de defectos (Roa et al., 1999; Osorio, 2021; Pabón y Osorio, 2019).

Actualmente, la evaluación y análisis de la calidad física del café en Colombia se desarrolla por medio de una persona capacitada para identificar de manera visual defectos del primer y segundo grupo. Este proceso toma un tiempo entre 25 a 30 minutos por cada muestra de 350 g, a la que corresponden aproximadamente 2186 granos de café. En consecuencia, el tiempo de evaluación y los factores que influyen sobre la valoración sensorial humana, tendrán efectos desfavorables en el procedimiento del análisis físico. El proceso es susceptible a los errores del observador-evaluador y a respuestas tardías en el diagnóstico, respecto a todas las valoraciones que se realizan en un tiempo determinado, perjudicando la eficacia y eficiencia del proceso. (Roa et al,1999; Osorio, 2021)

Por consiguiente, considerando las falencias identificadas con el apoyo de Tecnicafé, se plantea la siguiente pregunta problema: ¿Cómo se puede diseñar, implementar y validar un esquema de reconocimiento de defectos en el café almendra mediante el uso de visión computacional?

Objetivos

Objetivo general

- Diseñar e implementar un esquema de reconocimiento de defectos de café almendra a través de visión computacional.

Objetivos Específicos

- Determinar los tipos de defectos más relevantes en el café almendra para el proceso de reconocimiento visual y elaborar la respectiva base de datos de imágenes.
- Identificar las metodologías más adecuadas de reconocimiento visual e integrar un algoritmo que reconozca los defectos del café almendra por medio de visión computacional.
- Evaluar el desempeño del algoritmo a través de la comparación con lotes pre-evaluados de muestras.

Marco Teórico

En este capítulo, se presenta el fundamento teórico para el desarrollo de este trabajo, en donde se definen los conceptos fundamentales para realizar un proceso de clasificación por medio de imágenes, así como los conceptos técnicos concernientes al estudio de la calidad física del café. Además, se presenta información relevante de investigaciones previas, acerca de la clasificación de defectos físicos en el café almendra.

Marco Conceptual

Calidad del Café

La calidad de los alimentos está influenciada por diversos factores, como su valor nutritivo, estado sanitario, características organolépticas y aceptación del consumidor. Por lo tanto, para evaluar la calidad de los alimentos, es necesario tener conocimiento de sus propiedades y cualidades, así como identificar aquellas características que constituyen defectos o que no son aceptables para el consumo. En el caso específico del café, las características sensoriales adquieren una importancia mayor que su valor nutritivo, ya que la calidad del café se asocia con el compromiso del caficultor en la cadena productiva, para obtener una bebida con atributos sensoriales sobresalientes. En este sentido, las características organolépticas juegan un papel fundamental en la definición de la calidad física del café. (Roa et al,1999; Pabón y Osorio, 2019)

Análisis Sensorial del Café. El análisis sensorial del café es el estudio de aquellas propiedades que afectan los órganos de los sentidos del consumidor, consiste en describir, medir, analizar e interpretar aquellas características del café, que son percibidas por los sentidos (vista, olfato, gusto, tacto y oído). Este proceso de control de calidad asegura el uso de materias primas óptimas, así como la obtención de un producto uniforme, de buena taza y con el perfil esperado,

por lo tanto, es hasta ahora el método más eficiente para evaluar la calidad del café. (Roa et al,1999; Osorio, 2021)

Análisis Físico del Café. El análisis físico del café consiste en evaluar el aspecto visual del café, incluyendo la valoración del olor y color del pergamino, así como la evaluación de su aspecto general. Principalmente, se debe detectar e identificar cualquier tipo de defecto presente en una muestra de café almendra y determinar el porcentaje de almendra sana, que se refiere a la cantidad de granos sanos y sin defectos presentes en una cantidad determinada de café. (Roa et al,1999; Osorio, 2021)

En Colombia, se considera el porcentaje de humedad del café pergamino seco (10%-12%) como requisito para la compra de café, y se evalúa el porcentaje de almendra sana o factor de rendimiento. El precio del café obtenido en la comercialización depende de la calidad del café que se lleve al punto de compra. (Pabón y Osorio, 2019)

Los aspectos más importantes evaluados dentro de la calidad física del café son:

- Porcentaje de humedad: debe estar entre el rango de 10% al 12%.
- Porcentaje de almendra sana: es la cantidad de granos sanos, sin algún defecto presente en una cantidad determinada de café.
- Factor de rendimiento: es la cantidad de café pergamino seco que se necesita para obtener un saco de 70 kilogramos de café excelso. Actualmente, el promedio del factor de rendimiento en el país es de 92,8, que corresponden a 92,8 kg de café pergamino seco para obtener 70 kg de café excelso. Lo restante corresponde a cisco y defectos.

Specialty Coffee Association (SCA). La SCA es una asociación comercial construida sobre cimientos de apertura, inclusión y el poder del conocimiento compartido. El propósito de

SCA es fomentar las comunidades cafetaleras globales para apoyar actividades que hagan del café una actividad más sostenible, equitativa y próspera para toda la cadena de valor. Desde caficultores hasta baristas y tostadores, la SCA se extiende por todo el mundo y abarca todos los elementos de la cadena de valor del café. Actúa como una fuerza unificadora dentro de la industria del café de especialidad y trabaja para mejorarlo, elevando los estándares en todo el mundo a través de un enfoque colaborativo y progresivo, que se dedica a construir una industria que sea justa, sostenible y enriquecedora para todos. La SCA se basa en años de conocimientos e inspiración de la comunidad de cafés especiales. (Specialty Coffee Association, 2020)

La SCA tiene como una de sus actividades principales la difusión de información sobre el cuidado de la calidad y la validación del café a nivel mundial. En cuanto a la evaluación física del café, la SCA ha establecido una normativa de calidad para la valoración de si un tipo de café es de especialidad o no. Esta normativa se basa en la evaluación de una muestra de café almendra de 350g, donde se identifican y clasifican los defectos contenidos en ella.

En este sentido, la SCA define un total de 16 tipos de defectos, divididos en categoría 1 y categoría 2. Según esta normativa, para que un café sea considerado de especialidad, no se admitirá ninguna falta ocasionada por defectos de categoría 1, y se podrán admitir hasta 5 faltas ocasionadas por defectos de categoría 2. Además de la evaluación de los defectos, la SCA considera otros factores como el aroma, el sabor, la acidez, el cuerpo y el balance general de la taza para dar un veredicto sobre la calidad del café. Este riguroso proceso de evaluación garantiza que el café de especialidad cumpla con altos estándares de calidad y sabor (SCA, s.f.).

Defectos en el Café. Los granos de café con defectos deterioran la calidad de la bebida, porque producen sabores extraños, ásperos, acres, sucios, contaminados, fenólicos, químicos, terrosos, mohosos, agrios, fermentos, *stinker*, nauseabundos o reposados, y además, arriesgan la

inocuidad del café. Por consiguiente, deben evitarse, controlarse y retirarse antes del procesamiento y de la preparación final del producto. (Pabón y Osorio, 2019)

Según la SCA, el número de granos defectuosos equivalentes a una falta completa se muestra en la tabla 2.1. Este sistema permite a los evaluadores de café determinar el nivel de calidad de los granos y asegurar que se cumplan los estándares establecidos para los cafés de especialidad.

Tabla 2.1. *Equivalencias de los Defectos (SCA)*

Defectos Categoría 1	Número de Apariciones Equivalente una falta	Defectos Categoría 2	Número de Apariciones Equivalente a una falta
Grano negro	1	Grano negro parcial	3
Grano agrio	1	Grano agrio parcial	3
Cereza seca	1	Pergamino	5
Daño por hongos	1	Flotador	5
Materia extraña	1	Inmaduro	5
Broca	5	Averanado	5
		Concha	5
		Partido / Mordido / Cortado	5
		Cascarilla	5
		Dañado ligeramente por broca	10

En la elaboración de este trabajo se tuvieron en cuenta 10 tipos de defectos, además del tipo de grano sano, utilizando la información proporcionada por la SCA y Tecnicafé como referencia. A continuación, se describen de manera detallada cada uno de estos defectos:

Grano Almendra Sano. Los granos de café almendra son aquellos que no han sido sometidos a un proceso de tostado. Estos granos provienen directamente de las cerezas de café y pueden tener una amplia gama de colores, que van desde verde-azulados hasta tonos más parduzcos, dependiendo del origen o la edad del café. Sin embargo, es importante tener en cuenta que la inspección visual del café verde solo sirve como una referencia para los compradores, pero no forma parte de las especificaciones utilizadas para determinar la calidad de un café arábica lavado, de acuerdo con los estándares establecidos por la SCA.

Figura 2.1. *Café Almendra Sano*



Grano Negro. Los granos de café negros se caracterizan por tener un color opaco, lo cual es causado por un pigmento que se desarrolla como resultado de una sobre-fermentación provocada por microorganismos. Estos granos pueden evitarse mediante la recolección selectiva, exclusivamente de los frutos maduros de los cafetos y evitando condiciones propicias para la sobre-fermentación durante el procesado en la plantación.

Figura 2.2. *Granos Negros*



Grano Agrio. Los granos agrios se reconocen por su tonalidad de marrón amarillenta a marrón rojiza. Si el grano se corta o se raspa, libera un olor agrio similar al vinagre. Una vez tostado y molido un solo grano agrio puede contaminar una jarra entera de café. El grano agrio es consecuencia de la fermentación, que es el resultado de la contaminación microbiana en múltiples puntos durante la cosecha y el procesado.

Figura 2.3. *Granos Agrios*



Grano Cereza Seca. La pulpa seca suele cubrir parcial o completamente el pergamino del grano, y a veces puede presentar puntos blancos o residuos en polvo, lo cual es indicativo de la presencia de moho. Esto puede afectar tanto la calidad del café en la taza como su apariencia. En el caso de los cafés lavados, las cerezas secas son resultado de un proceso de despulpado insuficiente.

Figura 2.4. *Granos Cereza Seca*



Grano con Hongos. Los granos dañados por hongos se reconocen por sus manchas similares al polvo de color amarillo a marrón rojizo (esporas). A veces, se pueden ver como en forma de caracha en las primeras etapas del ataque, y van creciendo de tamaño hasta llegar a cubrir todo el grano. Los granos dañados por hongos liberan esporas que contaminan a los demás granos.

Figura 2.5. *Granos con Hongos*



Grano con Broca. Los granos atacados por la broca se distinguen por tener unas minúsculas perforaciones oscuras (entre 0,01 y 0,06 pulgadas - entre 0,3 y 1,5 milímetros de diámetro). El camino puede formar cualquier ángulo que puede ser longitudinal. En donde algunos granos pueden llegar a sufrir daños sustanciales, siendo frecuentes 3 o más perforaciones. Su causa es la broca, una de las plagas más importantes en la agricultura del café.

Figura 2.6. *Granos con Broca*



Grano Pergamino. Están contenidos total o parcialmente en una gruesa cascarilla parecida al papel de color blanco o tostado, este defecto se manifiesta en la molienda seca, y se debe a una calibración incorrecta de la máquina descascarilladora.

Figura 2.7. *Granos pergaminos*



Grano Flotador. Se caracterizan por tener un color blanco y apagado, y son granos de baja densidad que flotarán en agua debido a su procesamiento inadecuado. Este defecto suele originarse en un almacenamiento o secado inapropiados. Por lo general, los granos de pergamino que quedan en las esquinas de las secadoras o patios de secado resultan en una baja densidad, y el café pergamino almacenado en condiciones de humedad demasiado alta también puede dar lugar a granos flotadores.

Figura 2.8. *Granos Flotadores*



Grano Inmaduro. Se caracterizan por tener un color pálido, amarillo-verdoso en el endospermo o piel plateada del grano. La piel plateada está fuertemente adherida al grano y a menudo son más pequeños, curvados hacia adentro con forma cóncava y bordes puntiagudos.

Figura 2.9. *Granos Inmaduros*



Grano Averanado o Arrugado. Los granos averanados normalmente son más pequeños y están mal formados con arrugas que se asemejan a las de una uva pasa. El grano averanado está causado principalmente por la falta de agua (sequía) durante el desarrollo del grano dentro de la cereza.

Figura 2.10. *Granos Arrugados*



Grano Partido/ Mordido/ Cortado. Los granos mordidos o cortados normalmente presentan un color rojizo oscuro, debido a la oxidación de la zona donde se ha producido el corte durante el despulpado. Se producen durante el proceso de molienda seca, por lo que los fragmentos del grano están generalmente limpios y no muestran signos de oxidación.

Figura 2.11. *Granos Partidos/ Mordidos/ Cortados*



Visión Computacional

La Visión Computacional se basa en enseñar a los computadores a interpretar un grupo de imágenes a nivel de píxel, a entenderlas y a darle sentido a este tipo de datos por medio de técnicas avanzadas como *Machine learning* o *Deep Learning*. Técnicamente, las máquinas intentan recuperar la información visual, manejar, procesar e interpretar los resultados a través de algoritmos de software especiales. (Escalera Hueso, 2001)

Espacios de Color. Un modelo o espacio de color indica la manera en que un color está definido, y es una herramienta importante puesto que permite analizar y aprovechar toda la información presente dentro de la imagen. (Pérez, 2009)


Espacio RGB. El espacio de color *RGB* es la combinación de tres señales de luminancia cromática distinta: el rojo, el verde y el azul (*Red, Green, Blue*). La manera más sencilla de obtener un color concreto es determinar la cantidad de color rojo, verde y azul que se necesitan combinar,

por lo tanto, cada píxel estará compuesto por 3 componentes R , G y B . y la ecuación que define cualquier color en base al espacio RGB es:

$$X = R + G + B \quad (1)$$

En la representación gráfica de un color, X puede tomar cualquier valor de color, mientras que R , G y B representan las componentes en rojo, verde y azul respectivamente. Esta representación se visualiza como un cubo como se muestra en la Figura 2.12, donde los grises se encuentran en la recta que une el origen con el valor máximo, ya que las tres componentes tienen el mismo valor. (Escalera Hueso, 2001)

Figura 2.12. *Gráfico del espacio RGB*



Tomada de (Wikimedia Commons, 2008)

Espacio HSV. El espacio de color *HSV* se basa en el modo de percibir los colores que logramos ver los seres humanos, el cual caracteriza el color en términos de tono o tinte (*Hue*), saturación o cromatismo (*Saturation*) y brillo (*Intensity*).

Las transformaciones matemáticas que permiten el paso del espacio *RGB* a *HSV* son:


$$V = \frac{R + G + B}{3} \quad (2)$$

$$H = \arctan\left(\frac{\sqrt{3}(G - B)}{(R - G) + (R - B)}\right) \quad (3)$$

$$S = \frac{\min(R, G, B)}{V} \quad (4)$$

Gráficamente el espacio *HSV* se representa por medio de dos pirámides unidas por su base como se muestra en la Figura 2.13. Dependiendo del valor de la intensidad se tendrá un corte con las pirámides obteniéndose un triángulo. (Escalera Hueso, 2001)

Figura 2.13. Gráfico del espacio *HSV*



Tomada de (Wikipedia, 2022)

Espacio YCbCr. Este espacio se basa en la obtención de la luminancia (luminosidad) y la crominancia (color). No es un espacio de color absoluto, sino una forma de codificar información *RGB*. El color que se muestra depende de la combinación de colores primarios *RGB* usados para mostrar la señal. Este espacio de color se utiliza en sistemas de vídeo y fotografía digital en donde la componente de luma y las señales *Cb* y *Cr* son los componentes de crominancia, diferencia de azul y diferencia de rojo, respectivamente, su gráfico se observa en la Figura 2.14. (Escalera Hueso, 2001)


Las transformaciones matemáticas que permiten el paso del espacio *RGB* a *YCbCr* son:

$$Y = 16 + (65.481 * R + 128.553 * G + 24.966 * B) \quad (5)$$

$$Cb = 128 + (-37.797 * R - 74.203 * G + 112.0 * B) \quad (6)$$

$$Cr = 128 + (112.0 * R - 93.786 * G + 18.214) \quad (7)$$


Figura 2.14. Gráfico del espacio YCbCr



Tomada de (Wikipedia, 2023)

Espacio XYZ. El espacio de color XYZ es el nombre de uno de los primeros espacios de color definidos matemáticamente. Fue establecido en 1931 por la *Comission Internationale de l'Éclairage* (CIE). Con él se definieron con precisión los tres colores primarios de la síntesis aditiva de color, con los que se pueden crear todos los demás colores. En este espacio *Y* significa luminosidad, *Z* es aproximadamente igual al estímulo de azul, y *X* es una mezcla tendiente a la curva de sensibilidad del rojo al verde, este espacio se puede observar gráficamente en la Figura 2.15. (Escalera Hueso, 2001)

Figura 2.15. Gráfico del espacio XYZ




Tomada de (Wikipedia, 2023)

Histograma de una Imagen. El histograma de una imagen es una herramienta gráfica que muestra la distribución de niveles de gris o intensidades de color en la imagen. Representa el número de píxeles que tienen un determinado nivel de gris o intensidad de color, lo que puede entenderse como la probabilidad de que ese valor aparezca en la imagen. Una de las principales

ventajas del histograma es que condensa la información de la imagen en un conjunto reducido de valores, lo que facilita su análisis y comprensión. Por ejemplo, en la Figura 2.16 se muestra un ejemplo del histograma del plano G del espacio RGB de un grano de café. (Escalera Hueso, 2001)

Figura 2.16. *Histograma de Color*



Segmentación. La segmentación es un método que permite separar o dividir el objeto de interés del fondo de la imagen o de otros objetos, lo cual puede ser una tarea desafiante debido a la riqueza de la información visual en la imagen. Una vez realizada la segmentación, se procede a describir individualmente los objetos encontrados y a realizar su reconocimiento e interpretación. (Escalera Hueso, 2001)

La segmentación se basa en tres propiedades

- Similitud. Cada uno de los píxeles de un elemento tiene valores parecidos para alguna propiedad.
- Discontinuidad. Los objetos destacan del entorno y tienen por tanto unos bordes definidos.
- Conectividad. Los píxeles pertenecientes al mismo objeto tienen que ser contiguos.

Umbralización de la Imagen. La umbralización es un proceso que permite separar los píxeles del primer plano del fondo en una imagen. Este método implica el uso de un umbral, que es un valor predeterminado, para convertir la imagen en escala de grises en una imagen binaria, donde los píxeles se clasifican como primer plano o fondo según sus intensidades en relación con el umbral. Por lo general, se utiliza una imagen en escala de grises como entrada a este algoritmo, junto con un valor de umbral. La salida es una imagen binaria que muestra claramente la separación entre el primer plano y el fondo. La ecuación del umbral puede expresarse de la siguiente manera.

$$\begin{array}{l} \text{Píxel} < \text{Umbral} \\ \text{Píxel} > \text{Umbral} \end{array} \begin{cases} 0 \\ 1 \end{cases}$$

Si la intensidad de un píxel en la imagen de entrada es mayor que un umbral, el píxel de salida correspondiente se marca como blanco (primer plano), y si la intensidad del píxel de entrada es menor o igual que el umbral, la ubicación del píxel de salida se marca como negro.

Método Otsu. El método de *Otsu* es una técnica basada en la varianza utilizada para encontrar el valor de umbral óptimo en la segmentación de imágenes. Este método busca minimizar la varianza ponderada entre los píxeles del primer plano y del fondo. La idea principal es iterar a través de todos los posibles valores de umbral y medir la dispersión de los píxeles en el primer plano y el fondo. Luego, se encuentra el valor de umbral que minimiza la dispersión ponderada, lo que proporciona una segmentación precisa de la imagen.

Descriptores. Los descriptores son abstracciones de la información en la imagen y pueden incluir información relacionada con el color, la textura, la forma y el tamaño. Con base en estos descriptores o características se crea un vector modelo el cual es usado como entrada en los distintos modelos de clasificación. Los descriptores son muy importantes debido a que son las características que logran diferenciar las distintas clases.

Machine Learning (ML)

El *ML* o aprendizaje automático es la rama de la inteligencia artificial (IA) que se centra en enseñar a las computadoras la habilidad de aprender a partir del análisis de los datos, con el fin de identificar patrones, correlaciones en grandes *data sets*, apoyar en la toma de decisiones con la mínima intervención humana y mejorar con la experiencia en lugar de ser explícitamente programadas para hacerlo. Las aplicaciones del *ML* mejoran con el uso y se vuelven más precisas a medida que tienen acceso a más datos.

Los algoritmos de *ML* se dividen principalmente en dos categorías, la primera trata de descubrir las clases a las que pertenecen los datos basándose en las características que estos describen, mientras que la segunda enfoca la clasificación sabiendo las clases a las que pertenecen los datos, esto último se conoce como entrenamiento o aprendizaje. (Guido y Mueller,2016)

Aprendizaje Supervisado. El aprendizaje supervisado requiere datos de entrada y salida etiquetados durante la fase de entrenamiento del ciclo de vida del *ML*. Se llama aprendizaje supervisado porque al menos parte de este modelo requiere supervisión humana. La gran mayoría de los datos disponibles son datos brutos sin etiquetar. Por lo general, se requiere la interacción humana para etiquetar con precisión los datos. (Guido y Mueller,2016)

Eliminación de Descriptores en ML. Al construir un modelo de aprendizaje automático en la vida real, es poco común que todas las variables en el conjunto de datos sean relevantes para construir el modelo. Agregar variables redundantes puede disminuir la capacidad de generalización del modelo y reducir la precisión del clasificador en general. Además, aumentar la cantidad de variables en un modelo puede aumentar su complejidad en general. Por lo tanto, la selección de características se vuelve una parte indispensable en la construcción de modelos de aprendizaje automático.

El objetivo de las técnicas de selección de características en el aprendizaje automático es encontrar el mejor conjunto de características que permita construir modelos útiles para estudiar los fenómenos de interés. (Ferreira y Figueiredo, 2012; Pedregosa et al., 2011)

Eliminación de Características Recursivas (RFE). La *RFE* es una técnica utilizada en el aprendizaje automático para seleccionar descriptores de manera recursiva, basándose en un estimador externo que asigna pesos a los descriptores, como los coeficientes de un modelo lineal. El objetivo de *RFE* es encontrar el mejor conjunto de descriptores considerando conjuntos cada vez más pequeños. Inicialmente, el estimador se entrena en el conjunto completo de descriptores. Luego, se eliminan los descriptores menos importantes del conjunto actual en cada iteración. Este procedimiento se repite recursivamente en el conjunto resultante hasta alcanzar el número deseado de descriptores a seleccionar. (Pedregosa et al., 2011)

Modelos de Clasificación.

Decision Tree (DT). Los árboles de decisión son modelos predictivos formados por reglas binarias (si/no), con las que se consigue repartir las observaciones en función de sus atributos y predecir así el valor de la variable respuesta.

Muchos métodos predictivos, generan modelos globales en los que una única ecuación se aplica a todo el espacio muestral. Cuando el caso de uso implica múltiples predictores, que interaccionan entre ellos de forma compleja y no lineal, es muy difícil encontrar un único modelo global que sea capaz de reflejar la relación entre las variables. Los métodos estadísticos y de *ML* basados en árboles son técnicas supervisadas no paramétricas, que utilizan la segmentación del espacio de los predictores en regiones simples para facilitar el manejo de las interacciones. Esta

característica les confiere un alto potencial en la resolución de problemas diversos. En particular, técnicas como *Random Forest* y *Gradient Boosting Machine* se han posicionado como referentes en el ámbito predictivo debido a los excelentes resultados que ofrecen en una amplia gama de aplicaciones. (Guido y Mueller,2016)

Random Forest (RF). Un bosque aleatorio es un algoritmo de *ML* supervisado ampliamente utilizado debido a su precisión, simplicidad y flexibilidad. Es versátil ya que se puede utilizar tanto para tareas de clasificación como de regresión, y su naturaleza no lineal lo hace altamente adaptable a una variedad de datos y situaciones. A diferencia de un árbol de decisiones individual, que crea reglas para tomar decisiones, un bosque aleatorio es un grupo de árboles de decisión. Sin embargo, existen diferencias entre ambos enfoques. Mientras que un árbol de decisiones crea reglas específicas, un bosque aleatorio selecciona características al azar y realiza observaciones para construir un conjunto diverso de árboles de decisión. Luego, promedia los resultados de estos árboles para obtener una predicción final. La teoría detrás de los bosques aleatorios es que la combinación de múltiples árboles no correlacionados conduce a predicciones más precisas que un solo árbol de decisión. Esto se debe a que el conjunto de árboles trabaja en conjunto, para protegerse mutuamente de errores individuales y sobreajuste, lo que resulta en un modelo más robusto y generalizable. (Guido y Mueller,2016)

K-nearest neighbors (KNN). El algoritmo *KNN* es un clasificador de aprendizaje supervisado no paramétrico, que utiliza la proximidad como criterio principal para realizar clasificaciones o predicciones sobre la agrupación de un punto de datos individual. Se puede utilizar en problemas de regresión o clasificación, siendo comúnmente empleado como un algoritmo de clasificación y se basa en la suposición de que puntos similares tienden a estar cercanos uno al otro en el espacio de características.

En el proceso de clasificación con *KNN*, se asigna una etiqueta de clase basada en un voto mayoritario entre los k vecinos más cercanos a un punto de datos específico. Esto significa que se seleccionan los k puntos de datos más cercanos al punto a clasificar y se utiliza la etiqueta de clase que aparece con mayor frecuencia en estos vecinos para la clasificación del punto en cuestión. Este enfoque se conoce técnicamente como "voto por mayoría". El algoritmo *KNN* es sencillo de implementar y entender, lo que lo hace popular en muchas aplicaciones de aprendizaje automático. Sin embargo, es importante tener en cuenta que la elección adecuada del valor de k y la medida de distancia utilizada pueden afectar significativamente su rendimiento. (Guido y Mueller, 2016)

Support vector machine (SVM). El objetivo principal de *SVM* es encontrar un hiperplano en un espacio N -dimensional (N : el número de descriptores), que pueda clasificar de manera clara y precisa los puntos de datos. Para lograrlo, se pueden elegir entre varios hiperplanos posibles que puedan separar las clases. Sin embargo, el enfoque central es encontrar un plano que maximice el margen, es decir, la mayor distancia entre los puntos de datos de ambas clases. Al maximizar la distancia del margen, se obtiene un refuerzo adicional para realizar predicciones más confiables en datos futuros.

SVM es un algoritmo de aprendizaje supervisado ampliamente utilizado en problemas de clasificación y regresión. Se destaca por su capacidad para manejar problemas de clasificación binaria y su adaptabilidad para datos no lineales mediante el uso de funciones *kernel*. Además, *SVM* proporciona una mayor confiabilidad en la clasificación de datos gracias a su capacidad para encontrar un hiperplano con un margen amplio, lo que reduce la posibilidad de clasificar incorrectamente los puntos de datos. (Pedregosa et al., 2011; Betancourt, 2005)

Validación y Evaluación de la Clasificación

Validación Cruzada. Es un método estadístico ampliamente utilizado para estimar el rendimiento de modelos de aprendizaje automático, con el objetivo de proteger contra el sobreajuste en casos donde la cantidad de datos puede ser limitada. En este enfoque, se divide el conjunto de datos en un número fijo de pliegues (*K Folds*) de forma aleatoria o estratificada. Durante el proceso, todos los pliegues, excepto uno, se utilizan para entrenar el modelo, mientras que el pliegue restante se utiliza para la validación. Este proceso se repite hasta que todos los pliegues hayan sido utilizados como datos de validación al menos una vez. Finalmente, se calcula la media de las puntuaciones registradas como la métrica de rendimiento del modelo. La validación cruzada es especialmente útil en casos donde se busca una estimación robusta y confiable del rendimiento del modelo en datos no observados, y es una práctica común en la evaluación de modelos de aprendizaje automático. (Browne, 2000; Berrar, 2019)

Matriz de Confusión. Una matriz de confusión es una herramienta esencial en el aprendizaje supervisado que permite visualizar el desempeño de un algoritmo. Se representa como una tabla en la que cada columna muestra el número de predicciones para cada clase, y cada fila representa las instancias en la clase real. Esta información se utiliza para calcular métricas de evaluación o indicadores de desempeño, que determinan la capacidad del algoritmo para clasificar correctamente las distintas clases. La matriz de confusión proporciona una visión clara y detallada de las predicciones del modelo, lo que permite evaluar su precisión, sensibilidad, especificidad, y otras métricas importantes. Es una herramienta valiosa para el análisis y la mejora de los modelos de aprendizaje supervisado, ayudando a identificar y corregir posibles errores de clasificación. En la Figura 2.17 se muestra un ejemplo de una matriz de confusión de dos clases. (Pedregosa et al., 2011)

Figura 2.17. *Matriz de Confusión 2x2*

		Predicciones	
		Positivos	Negativos
Valores Reales	Positivos	Verdaderos Positivos (VP)	Falsos Negativos (FN)
	Negativos	Falsos Positivos (FP)	Verdaderos Negativos (VN)

- Positivos (P): La observación es positiva.
- Negativos (N): La observación no es positiva
- Verdadero Positivo (VP): Resultado en el que el modelo predice correctamente la clase positiva.
- Verdadero Negativo (VN): Resultado donde el modelo predice correctamente la clase negativa.
- Falso Positivo (FP): También llamado error de tipo 1, resultado donde el modelo predice incorrectamente la clase positiva cuando en realidad es negativa.
- Falso Negativo (FN): También llamado error de tipo 2, un resultado en el que el modelo predice incorrectamente la clase negativa cuando en realidad es positiva.

Métricas de Desempeño. Las componentes internas de la matriz de confusión ofrecen diversas métricas, que resultan de gran utilidad para evaluar el desempeño de un clasificador y, especialmente, para poder compararlo con otros. Algunas de estas métricas son:

- Exactitud (*Accuracy*)
- Precisión (*Precision*)
- Sensibilidad (*Recall*)

➤ Índice F1 (*F1 Score*)

Estas son unas de las métricas más importantes (junto con el F1-Score) que se pueden obtener de la matriz de confusión y por tanto se pueden identificar cuatro casos posibles al analizar el comportamiento de sus valores con respecto a la clase positiva:

1. Alta *precision* y alto *recall*: el modelo maneja perfectamente esa clase. Se trata de un buen modelo de clasificación para poder implementar.
2. Alta *precision* y bajo *recall*: el modelo no detecta la clase «perseguida» muy bien, pero cuando lo hace es altamente confiable.
3. Baja *precision* y alto *recall*: El algoritmo detecta bien la clase «perseguida» pero también incluye muestras de la/s otra/s clase/s.
4. Baja *precision* y bajo *recall*: El modelo no logra clasificar la clase correctamente. No sería bueno seguir adelante con la implementación de dicho modelo.

Accuracy. Se define como la proporción que existe entre las predicciones realizadas correctamente sobre el total de predicciones realizadas. Por tanto, es el cociente entre los casos bien clasificados por el modelo (verdaderos positivos y verdaderos negativos, es decir, los valores en la diagonal de la matriz de confusión), y la suma de todos los casos. (Pedregosa et al., 2011)

$$Accuracy = \frac{VP + VN}{VP + VN + FP + FN} \quad (8)$$

Precision. La *precision* se fija solamente en la clase positiva o en una clase en particular y su objetivo es dar la proporción de aciertos de esa clase (es decir observaciones predichas como positivo que realmente eran positivo) sobre el total de predicciones de positivo. Se refiere a lo cerca que está el resultado de una predicción del valor verdadero. Por tanto, es el cociente entre los casos positivos bien clasificados por el modelo y el total de predicciones positivas. En otras

palabras, responde a la pregunta "¿Qué proporción de identificaciones o predicciones positivas fue realmente correcta?". (Pedregosa et al., 2011)

$$Precision = \frac{VP}{VP + FP} \quad (9)$$

Recall. Indica la capacidad de nuestro estimador para discriminar los casos positivos, de los negativos también conocida como Tasa de Verdaderos Positivos (*True Positive Rate*, TPR). Es la proporción de casos positivos que fueron identificados correctamente por el algoritmo respecto a los casos reales positivos. Responde a la pregunta "¿Qué proporción de positivos reales se identificó correctamente?" (Pedregosa et al., 2011)

$$Recall = \frac{VP}{VP + FN} \quad (10)$$

F1 Score. Este índice resume la *precision* y *recall* en una sola cifra, se calcula como la media armónica entre *precision* y *recall*. Es una métrica equilibrada entre tener pocos falsos positivos y pocos falsos negativos, puede tener una puntuación máxima de 1 (*precision* y *recall* perfectos) y una mínima de 0. (Pedregosa et al., 2011)

$$F1\ Score = \frac{Precision * Recall}{Precision + Recall} = \frac{2VP}{2VP + FN + FP} \quad (11)$$

Marco Referencial

En este apartado, se resumen las características más importantes de los trabajos encontrados que se realizaron en el campo de la detección o clasificación de defectos en el café almendra por medio de visión computacional.

Trabajos Anteriores

Los trabajos sobre el reconocimiento automático de defectos en los granos de café almendra serán descritos por los siguientes parámetros:

- Tipos de defectos a clasificar
- Tamaño base de datos
- método de segmentación
- Descriptores
- Modelo de clasificación
- Evaluación del modelo (métricas)

En el estudio realizado por García et. al (2019), se definieron 6 clases diferentes de granos, incluyendo agrio, baya larga, negro, mordido, inmaduro y normal. La base de datos utilizada en el estudio constó de 220 imágenes en total, que incluían un total de 544 granos. Para obtener las fotografías, se utilizó un fondo blanco y se aplicó un filtro de eliminación de ruido gaussiano. Luego, se usaron métodos de umbralización para segmentar los granos en las imágenes. Además, se extrajeron 4 descriptores específicos para caracterizar los granos, como la excentricidad, el área superficial, la redondez y la relación de área particular. Para la clasificación de los granos, se aplicó el algoritmo *KNN*, que obtuvo un alto nivel de precisión del 95,66%, con una desviación estándar de 2,03%.

En el trabajo realizado por Pino et al. (2017), se establecieron seis categorías para clasificar los diferentes tipos de granos de café: flotador, negro, agrio, roto, *peaberry* y sin defecto. Para ello, se utilizó una base de datos que constaba de un total de 13000 imágenes, correspondientes a ambos lados de 6,500 granos, y se capturaron fotografías con un fondo de color blanco. Para llevar a cabo la clasificación, se implementó un modelo de redes neuronales convolucionales (CNN) profundas.

Los resultados obtenidos mostraron un *accuracy* variando entre el 72.4% y el 98.7% para cada clase, con una precisión global promedio del 80%.

En el estudio de Portugal et al. (2016), se establecieron 13 clases, que incluyen Brocado Leve, Brocado Severo, Cereza Seca, Concha, Daño por Hongo, Flotador, Inmaduro, Vinagre, Negro, Normal, Negro Parcial, Pergamino y Partido. La base de datos utilizada para este estudio consistió en un total de 1930 imágenes. Para la captura de estas imágenes, se diseñó un prototipo robusto que demostró ser altamente eficiente en la obtención de imágenes de alta calidad. En cuanto al pre-procesamiento de las imágenes, se aplicó un algoritmo *White-Patch*, que forma parte de la familia de algoritmos de constancia de color *Retinex*, y se utilizó el algoritmo de *Otsu* como método de segmentación. Además, se llevó a cabo un proceso de erosión y dilatación para mejorar la calidad de las imágenes y Para la extracción de características, se definieron 768 descriptores basados en los histogramas de color para cada canal del espacio RGB, y se utilizó el método de clasificación *SVM*. La evaluación del sistema se realizó mediante validación cruzada con $K = 10$ *Folds*, obteniendo un *accuracy* del 98,8% con el uso del algoritmo *White-Patch* y del 83% sin este algoritmo.

En el estudio realizado por Santos et al. en 2020, se definieron 5 clases diferentes para clasificar las imágenes: normal, agrio, roto, negro y con cáscara. La base de datos utilizada contenía un total de 635 imágenes con fondo blanco, y se extrajeron 15 descriptores para su análisis. Estos descriptores incluyeron áreas, medias de intensidad en los planos *B*, *G* y *R* del espacio de color *RGB*, así como circularidad, compacidad, convexidad, excentricidad, medias de intensidad en los planos *H*, *S* y *V* del espacio de color *HSV*, longitud, perímetro, solidez y medias de intensidad en los planos *R*, *G* y *S* del espacio de color *HSV*.

Para la clasificación, se probaron tres modelos diferentes: *SVM*, *Deep Neural Network* y *RF*. Los resultados obtenidos mostraron que el modelo *SVM* alcanzó una precisión del 94,8%, mientras que la *Deep Neural Network* obtuvo una precisión del 88,5% y el modelo *RF* alcanzó una precisión del 94,7%.

En el trabajo realizado por Janandi y Cenggoro en 2020, se definieron tres clases de acuerdo con los grados 1, 2 y 3. La base de datos utilizada constó de un total de 160 imágenes. Se realizaron pruebas utilizando dos modelos de redes neuronales convolucionales (CNN), específicamente *VGG16* y *ResNet-152*. Los resultados obtenidos indicaron que la *accuracy* alcanzada fue del 58.7% para *VGG16* y del 62.3% para *ResNet-152*, utilizando un conjunto de datos compuesto por 110 imágenes divididas en conjuntos de entrenamiento, prueba y validación con proporciones de 70%, 20% y 20% respectivamente. Posteriormente, se llevó a cabo una segunda fase de pruebas con un conjunto de datos más amplio, compuesto por 160 imágenes y dividido en conjuntos de entrenamiento, prueba y validación en proporciones de 90%, 35% y 35% respectivamente. Los resultados obtenidos en esta fase mostraron una mejora en la precisión, alcanzando un 66.8% para *VGG16* y un 73.3% para *ResNet-152*.

En resumen, los investigadores utilizaron una base de datos de 160 imágenes y probaron dos modelos de *CNN*, *VGG16* y *ResNet-152*, en dos conjuntos de datos diferentes. Los resultados mostraron que la precisión de ambos modelos mejoró en la segunda fase de pruebas, donde se utilizó un conjunto de datos más amplio.

En el estudio realizado por Pizzaia y su equipo en 2018, se establecieron dos clases para la clasificación de los granos: granos buenos y granos malos defectuosos. La base de datos utilizada constaba de 848 imágenes capturadas con fondo blanco, de las cuales se seleccionaron 748 para el entrenamiento del modelo y 100 para la validación. Para la segmentación, se empleó el método de

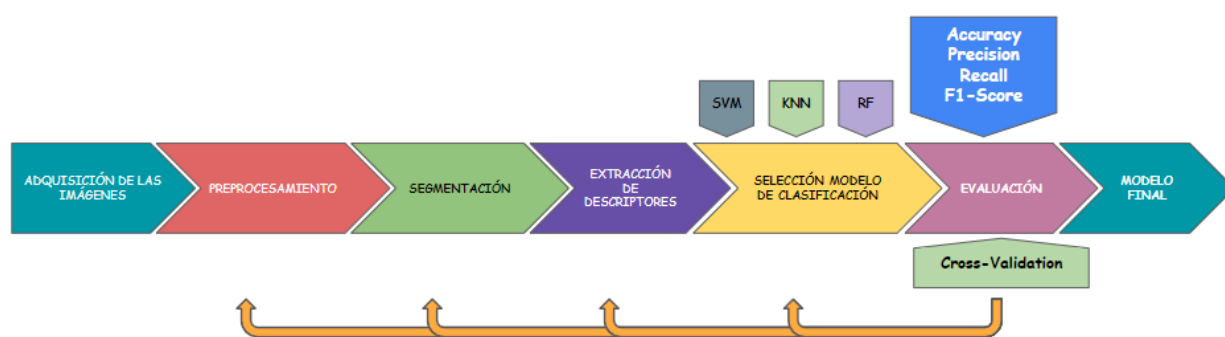
binarización de *Otsu*, y se utilizaron varios descriptores, como el área, redondez, y las medias de intensidad de los planos *R*, *G* y *B* del espacio *RGB*, para la clasificación de los granos. Como modelo de clasificación, se implementó una Red Neuronal del tipo *Multilayer Perceptron*. Los resultados obtenidos mostraron un *accuracy* del 92,86% para la clasificación de los granos buenos y del 95,35% para los granos malos defectuosos. En promedio, el clasificador alcanzó un *accuracy* del 94,10%.

En el trabajo de Huang y su equipo en 2020, se propusieron dos categorías: "bueno" y "malo". Para entrenar su modelo de clasificación, utilizaron una base de datos compuesta por 72000 imágenes con fondo blanco. Emplearon una *CNN* y los resultados fueron prometedores. En los *epochs* 10 y 15, el clasificador alcanzó tasas de *accuracy* del 93.47% y 94.63%, respectivamente.

Metodología

En esta sección, se proporciona una descripción detallada de los métodos y procedimientos utilizados en la obtención del modelo de reconocimiento y clasificación de defectos en el café almendra. El diseño del esquema del modelo propuesto en este estudio se ilustra en la Figura 3.1, donde se detallan las etapas y componentes clave del proceso.

Figura 3.1. *Esquema Para la Clasificación de Defectos*



1. Selección de los Granos

Las muestras de café almendra utilizadas en este estudio fueron proporcionadas por Tecnicafé, quien también brindó asesoría y criterio en la selección y validación de las muestras. Para llevar a cabo esta tarea, se siguió el estándar internacional de la SCA, reconocido a nivel mundial. En este proceso, se tuvieron en cuenta la mayoría de los defectos físicos clasificados como categoría 1 y 2. A continuación, en la Tabla 3.1 se detallan los tipos de defectos que fueron seleccionados para este trabajo.

Tabla. 3.1 *Defectos*

Categoría 1	Categoría 2
Grano negro	Pergamino
Grano agrio	Flotador
Cereza seca	Inmaduro
Daño por hongos	Arrugado
Broca	Partido/ mordido/ cortado

Adicionalmente, se tomó en consideración la distinción entre los granos sanos o normales, lo cual condujo a la definición de un total de 11 clases, que incluyen diez tipos de defectos y los granos sanos. Para cada una de estas clases, se recolectaron meticulosamente 120 granos con el fin de asegurar una muestra representativa y confiable.

2.Captura de Imágenes

El montaje para la captura de las imágenes estuvo compuesto por:

➤ Cámara Canon:

Modelo: Canon EOS 7D Mark II

Tiempo de exposición: 1/80s

Velocidad ISO: ISO 100

Distancia focal: 122mm

➤ Dos lámparas LED:

Potencia: 50 watts

➤ Trípode

➤ Fondo blanco

➤ Soporte para lámparas


Se diseñó un soporte para las lámparas utilizando tubos de PVC, con una altura de 140 cm y un ancho de 94 cm. Las lámparas se suspendieron en el soporte, manteniendo una distancia de 40 cm entre ellas para asegurar una iluminación uniforme. La cámara se colocó estratégicamente en la mitad de las dos lámparas, siendo sostenida por un trípode con una altura de 100 cm, con el fin de obtener la mejor posición para la captura de imágenes. El montaje completo se puede apreciar en la Figura 3.2, proporcionando una visualización clara de la disposición de los elementos.

Figura 3.2. *Montaje Para la Captura de Imágenes*



Las imágenes se capturaron desde una perspectiva de Plano Cenital, con la cámara posicionada perpendicular al suelo en un ángulo de 90 grados. Se tuvo especial cuidado en incluir la mayor cantidad de granos en cada toma, evitando que se tocaran entre sí y asegurándose de que estuvieran dentro del plano de captura de las fotos, como se puede apreciar en la Figura 3.3.

Figura 3.3. *Fotografía Ejemplo de las Muestras*




3.Preprocesamiento

En esta etapa se llevó a cabo el primer tratamiento por el que pasaron las imágenes, que consistió en el proceso de filtrado de ruido y aplicación de un conjunto de técnicas de preprocesamiento para obtener imágenes mejoradas.

Recorte de Imágenes

Después de que las imágenes se almacenaran en formato digital y en el espacio de color *RGB*, se procedió a seccionar y recortar cada imagen. Para este proceso primero se pasaron las imágenes a escala de grises y se aplicó una segmentación automática por medio del método *Otsu*, como se muestra en la Figura 3.4


Figura 3.4. *Imagen Segmentada*



Tras llevar a cabo el proceso de segmentación, se detectó la presencia de ruido en las imágenes, como se evidencia en la Figura 3.4. En el círculo amarillo se observaron píxeles blancos que no correspondían a los granos de café, mientras que en el círculo verde se apreciaban píxeles negros dentro de los granos, lo cual indicaba una segmentación incorrecta. Para abordar estos problemas, se procedió a aplicar operaciones morfológicas de apertura y cierre, con el fin de

mejorar la calidad de las imágenes segmentadas. Como resultado de estas correcciones, se obtuvieron imágenes segmentadas sin ruido, tal como se muestra en la Figura 3.5.

Figura 3.5. *Imagen Segmentada sin Presencia de Ruido*



Posteriormente, se llevó a cabo la identificación de todos los componentes o granos de café presentes en cada imagen. Se obtuvieron las coordenadas y medidas del rectángulo delimitador de cada grano, y a partir de estas coordenadas se dibujó un rectángulo delimitador, tal como se muestra en la Figura 3.6, después, se recortaron las imágenes siguiendo esta plantilla, como se ilustra en la Figura 3.7. Como resultado de este proceso, se obtuvo 110 imágenes de cada clase, lo que suma un total de 1210 imágenes en la base de datos.

Figura 3.6. *Rectángulos Delimitadores Para Cada Grano*




Figura 3.7. *Imágenes Recortadas Para Cada Grano*



Eliminación de Ruido

Con el fin de obtener imágenes mejoradas y sin ruido, se realizó un proceso de normalización y filtrado en cada imagen. En el caso del filtrado de ruido, se aplicó un filtro o suavizado *Gaussiano 2D* con *kernel* (7,7) en donde la imagen de salida se observa en la Figura 3.8 b.

Figura 3.8. (a) *Grano Arrugado sin Filtro Gaussiano*, (b) *Grano Arrugado Después del Filtro Gaussiano*




(a)

(b)

4.Segmentación

El proceso de segmentación, se llevó a cabo por medio de la implementación del método *Otsu* en toda la base de datos, con el fin de generar máscaras, como la que se observa en la Figura 3.9 b, después de la segmentación, la máscara pasó por un proceso de eliminación de ruido, en donde por medio de un algoritmo se eliminaron los huecos existentes y se escogió el componente identificado con más píxeles perteneciente al grano de café, descartándose grupos pequeños de píxeles que eran ruido. Mediante las máscaras se obtuvo la información más relevante para la adquisición de descriptores, ya que estas anulaban la información del fondo y preservaban la información del grano (Figura 3.9 c).

Figura 3.9. (a) *Imagen con Filtro Gaussiano* (b) *Máscara de la Imagen* (c) *Implementación de Máscara*



5.Extracción de Descriptores

La selección y extracción de descriptores se basó en las características visuales que son observables en los distintos tipos de defectos presentes en los granos de café. Se notó que las clases de defectos seleccionadas se diferencian principalmente por el color, seguido de la textura y la forma de los granos. Por lo tanto, se propusieron descriptores que abarcan el color, forma, tamaño y textura de los granos de café, los cuales se describen de forma detallada a continuación.

Descriptores de Color

Los defectos en los granos de café presentan diferencias significativas en términos de color, lo cual es un factor fundamental en el proceso de descripción física y clasificación de los mismos, según lo establecido por la SCA. Por lo tanto, tras llevar a cabo una minuciosa revisión visual de los diversos tipos de defectos, se determinó que el color sería la característica primordial para la extracción de la mayor cantidad de descriptores.

Con el fin de caracterizar el color de manera exhaustiva, se utilizaron cuatro espacios de color: *HSV*, *RGB*, *YCbCr* y *XYZ*. Se procedió a convertir cada imagen *RGB* a los distintos espacios

de color y se extrajeron los planos correspondientes a cada uno, como se puede apreciar en las Figuras 3.10, 3.11, 3.12 y 3.13. Esta metodología permitió obtener información detallada acerca de las propiedades cromáticas de los defectos en los granos de café, estableciendo una base sólida para el análisis y clasificación de los mismos con precisión y rigor.

Figura 3.10. Planos del espacio RGB




Figura 3.11. Planos del espacio HSV



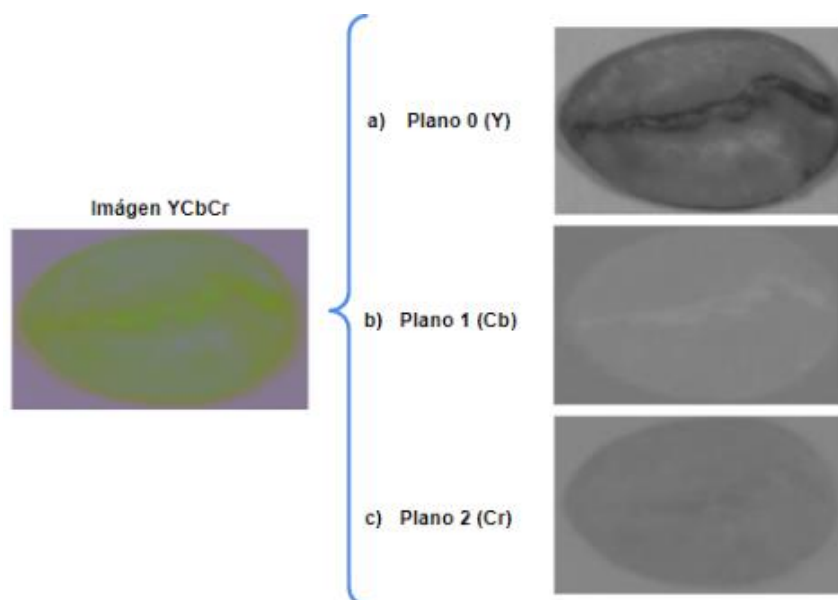


Figura 3.12. Planos del espacio XYZ**Figura 3.13.** Planos del espacio YCbCr

A partir de los planos de color obtenidos, se procedió a la extracción de los descriptores que se detallan a continuación, con el objetivo de obtener una caracterización detallada de los defectos en los granos de café:

Histogramas de Niveles de Intensidad. El histograma muestra la distribución de la probabilidad de los niveles de intensidad, siendo esta la base para la extracción de los descriptores de color. En la Figura 3.14 se observa que las bases de los rectángulos en el eje x , son los diferentes intervalos de valores de intensidad que puede tomar un píxel en la imagen, y las alturas respectivas de los rectángulos en el eje y , son las frecuencias de cada uno de los intervalos de los niveles de intensidad, definiendo cada descriptor como la cantidad de píxeles existentes en la imagen para cada intervalo de nivel de intensidad, es decir, el valor de la frecuencia de cada uno de los intervalos de los niveles de intensidad.

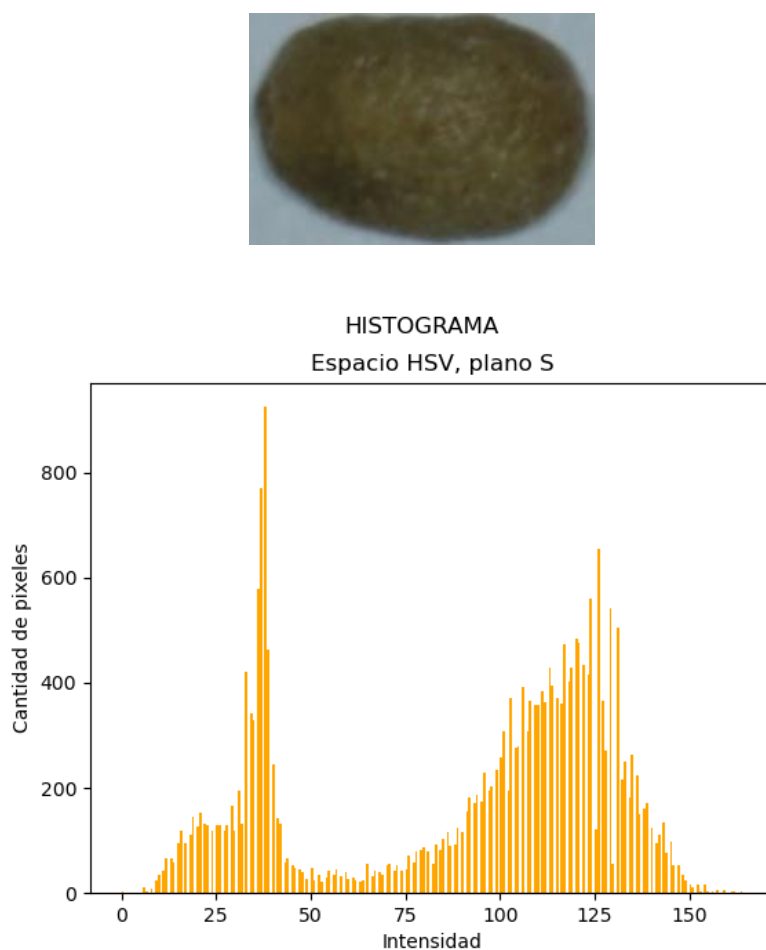
De cada imagen se extrajeron histogramas de los siguientes planos:

- Plano B y G del espacio de color RGB
- Plano X del espacio de color XYZ
- Planos H y S del espacio de color HSV
- Plano Y , Cb y Cr del espacio de color $YCbCr$

Por cada imagen se obtuvieron ocho histogramas de aproximadamente 100 intervalos de intensidades cada uno. Posteriormente para representar cada una como un vector de descriptores, se utilizaron 100 descriptores del histograma del canal B , 100 descriptores del histograma del canal G , 100 descriptores del histograma del canal H , 100 descriptores del histograma del canal S , 87 descriptores del histograma del canal Y , 100 descriptores del histograma del canal Cb , 100 descriptores del histograma del canal Cr y 100 descriptores del histograma del canal X , por lo que

cada imagen de cada grano estuvo representada por 787 descriptores de color, extraídas por medio de histogramas. La representación gráfica de un histograma de un grano de café se muestra a continuación en la Figura 3.14

Figura 3.14. Histograma de un grano con defecto tipo vinagre



Promedio de Intensidades. Para obtener otro tipo de descriptores de color se halló el promedio de intensidad de todos los planos pertenecientes a los espacios *RGB*, *XYZ* y *HSV* mostrados en las Figuras 3.10, 3.11, 3.12. Para extraer el promedio, se implementó la máscara de la Figura 3.9 b para solo tener en cuenta el área de interés, es decir, los píxeles que conforman el grano y no los del fondo, mediante la ecuación (12), en donde \bar{X} es el promedio de intensidad en

la imagen, n el número total de píxeles, i es el índice o contador y x es el valor de intensidad de cada píxel. Con ello, se obtuvieron nueve descriptores adicionales, equivalentes a los promedios de intensidad de los planos de los espacios RGB , XYZ y HSV .

$$\bar{X} = \frac{\sum_{i=1}^n x_i}{n} \quad (12)$$

Desviación Estándar. La desviación estándar es la medida de dispersión más común, que indica qué tan dispersos están los datos alrededor de la media. En este caso, se obtuvo un valor que cuantificaba qué tan dispersos están los valores de intensidad de todos los píxeles, respecto al promedio de intensidad de los píxeles en la imagen. Se obtuvo la desviación estándar de todos los planos de los espacios HSV , RGB , XYZ y $YCbCr$. Por tanto, se obtuvieron 12 descriptores adicionales, los cuales se añadieron al vector de descriptores.

Descriptores de Forma y Tamaño

La forma de los granos de café después de ser descascarados se convierte en una característica diferenciadora, debido a que los distintos tipos de defectos en su mayoría tienen levemente diferente forma y tamaño. A partir de relaciones de área y perímetro se extrajeron 5 descriptores o rasgos geométricos, tales como compacidad, factor de forma o redondez, factor de compacidad, perímetro y perímetro de contacto, por lo que mediante estos valores numéricos se cuantificó la geometría y forma del grano.

Para hallar el perímetro y área del grano se tuvieron en cuenta las siguientes relaciones:

➤ **perímetro:**

El perímetro se calcula fácilmente, sumando los píxeles del contorno. Si se tienen las coordenadas de todos los puntos, se puede calcular usando la ecuación 13 en donde X y Y pertenecen a las coordenadas de cada píxel. (Borrero Becerra y Diaz Molano)

$$Perímetro = \sum_{K=0}^N \sqrt{(X_{K+1} - X_K)^2 + (Y_{K+1} - Y_K)^2} \quad (13)$$

➤ Área

El área es la suma de los píxeles del objeto que aparecen en la imagen. Se obtiene con la ecuación 14, donde, I_{ij} corresponde al valor de intensidad de una imagen binaria. En una imagen binaria $I_{ij}=0$ cuando el píxel no es parte del objeto, y $I_{ij}=1$ cuando sí lo es. (Borrero Becerra y Diaz Molano)

$$Área = \sum_i \sum_j I_{ij} = 1 \quad (14)$$

Con base en estas relaciones y la máscara se hallaron los valores del área y el perímetro o contorno. En la figura 3.15, se observa el contorno en color rojo alrededor del grano de café y el área que sería la región que encierra el contorno rojo.

Figura 3.15. Contorno y área de un grano de café



A partir de los valores de área y del descriptor perímetro, se hallaron cuatro descriptores extra que se incorporaron en el vector de descriptores: compacidad, factor de forma, factor de compacidad y perímetro de contacto, siguiendo las ecuaciones:

$$\text{Compacidad} = \frac{2\sqrt{A\pi}}{P} \quad (15)$$

$$\text{Factor de forma} = \frac{4A\pi}{P^2} \quad (16)$$

$$\text{Factor de Compacidad} = \frac{A - \frac{P}{2} + 1}{A - 2\sqrt{A} + 1} \quad (17)$$

$$\text{Perímetro de contacto} = \frac{4A - P}{2} \quad (18)$$

Descriptores de Textura

Los distintos tipos de defectos del café se pueden llegar a diferenciar unos de otros por su textura ya que algunos son rugosos y otros lisos. Un método estadístico para analizar la textura que considera la relación espacial de los píxeles, es la matriz de coocurrencia de nivel de gris (GLCM), también denominada la matriz de dependencia espacial de escala de gris. La *GLCM* es una herramienta estadística que permite caracterizar la textura de una imagen, al calcular la frecuencia con la que los pares de píxeles que muestran valores específicos y se encuentran en una relación espacial concreta ocurren en la imagen, creando una *GLCM* y, después, extrayendo medidas estadísticas de esta matriz. Una vez creadas las *GLCM* se derivaron cuatro medidas estadísticas es decir cuatro descriptores. Estos descriptores proporcionaron datos significativos sobre la textura de los diversos defectos del café, y se incluyeron en el vector de descriptores utilizado en el análisis. A continuación, se detallan los descriptores obtenidos:

1. Contraste: Mide las variaciones locales de la matriz de coocurrencia de nivel gris.
2. Correlación: Mide la probabilidad de aparición conjunta de los pares de píxeles especificados.

3. Energía: Proporciona la suma de elementos al cuadrado de la *GLCM*. También conocido como uniformidad o el segundo momento angular.
4. Homogeneidad: Mide la cercanía de la distribución de elementos de la *GLCM* a la diagonal de la *GLCM*.

6. Clasificación

Después de obtener los descriptores, se procedió a la clasificación, utilizando tres modelos diferentes: *KNN*, *SVM* y *RF*, ya que se han aplicado con éxito en estudios previos (García et al., 2019; Portugal-Zambrano et al., 2016; Santos et al., 2020). Cada modelo tiene sus propias especialidades, lo que permitió evaluar los 817 descriptores extraídos desde diversas perspectivas. Todos los modelos se implementaron utilizando validación cruzada con $K=5$ *Folds*.

7. Evaluación de la clasificación

Con el objetivo de obtener y elegir el mejor modelo de clasificación, se calcularon 4 métricas de evaluación de rendimiento. En este sentido, se analizaron los valores de *accuracy*, *F1_score*, *precision* y *recall*. A partir de estos parámetros, se determinó que el modelo *RF* fue el mejor en términos de rendimiento.

8. Depuración y Selección de Descriptores

Hay varias razones para reducir el número de descriptores al mínimo las cuales mejoran el rendimiento del modelo y disminuyen el coste o complejidad computacional, tanto en la etapa de caracterización como en la clasificación. Además, muchas veces dos descriptores pueden aportar información adecuada para la clasificación cuando se utilizan por separado, pero si son altamente correlacionados, la ganancia es poca al utilizarlos o pueden existir descriptores redundantes que contengan la misma información que otros descriptores. (Hall, 1999)

Se obtuvieron en total 817 descriptores basados en el color, forma y textura. Sin embargo, debido a las razones mencionadas previamente, fue necesario llevar a cabo una reducción masiva con el fin de seleccionar únicamente los descriptores más relevantes y, al mismo tiempo, preservar la información discriminante. Para llevar a cabo esta selección, se utilizó uno de los modelos más populares conocido como eliminación de características recursivas con validación cruzada (RFECV). Este modelo permite identificar el mejor subconjunto de descriptores para el estimador o modelo proporcionado, mediante un proceso de eliminación recursiva que va desde 0 hasta N descriptores (donde N es el número total de descriptores), y seleccionando el subconjunto óptimo en función de la puntuación de validación cruzada del modelo. Se aplicó este modelo con un enfoque de validación cruzada de $K=5$ *Folds* y se utilizó *RF* como modelo. Como resultado de la aplicación de *RFECV*, finalmente se seleccionaron 323 descriptores.

Resultados y Análisis

Selección del Mejor Modelo

A partir de los 817 descriptores propuestos anteriormente y la aplicación de validación cruzada con $K=5$ *Folds*, se obtuvieron los siguientes resultados para los tres modelos

1. Support vector machine

Tabla 4.1. *Métricas de desempeño para SVM*

Subconjunto	Accuracy	Precision	Recall	F1-Score
1	0.8864	0.8845	0.8797	0.8791
2	0.8954	0.8874	0.8863	0.8840
3	0.9000	0.9037	0.8966	0.8977
4	0.9181	0.9259	0.9207	0.9210
5	0.9090	0.9154	0.9150	0.9105
Promedio	0.9018	0.9033	0.8997	0.8985

2. K-Nearest Neighbor

Tabla 4.2. *Métricas de desempeño para KNN*

Subconjunto	Accuracy	Precision	Recall	F1-Score
1	0.8318	0.8336	0.8178	0.8185
2	0.7909	0.8062	0.8011	0.7847
3	0.8136	0.8188	0.8076	0.8057
4	0.7909	0.8086	0.8046	0.7969
5	0.8182	0.8328	0.8141	0.8116
Promedio	0.8091	0.8199	0.8090	0.8035

3. Ramdon Forest

Tabla 4.3. Métricas de desempeño para RF

Subconjuntos	Accuracy	Precision	Recall	F1-Score
1	0.9227	0.9231	0.9210	0.9215
2	0.9500	0.9462	0.9508	0.9477
3	0.9545	0.9562	0.9537	0.9544
4	0.9318	0.9388	0.9274	0.9302
5	0.9454	0.9467	0.9482	0.9461
Promedio	0.9410	0.9422	0.9402	0.9399

A partir de la información contenida en las Tablas 4.1, 4.2 y 4.3 se generaron las siguientes gráficas:

Figura 4.1. Gráfica del accuracy para los modelos SVM, KNN, RF




Figura 4.2. Gráfica de la precision para los modelos SVM, KNN, RF




Figura 4.3. Gráfica del recall para los modelos SVM, KNN, RF





Figura 4.4. Gráfica del *f1-score* para los modelos *SVM*, *KNN*, *RF*



En las Figuras 4.1, 4.2, 4.3, 4.4 y Tablas 4.1, 4.2, 4.3 están representados todos los valores de las métricas de desempeño de cada subconjunto para cada modelo. Al evaluar y comparar los promedios y valores para cada subconjunto de las métricas, se percibe notoriamente que el modelo *RF* tiene mejor desempeño por cada métrica en comparación a los otros modelos, obteniendo un *accuracy* medio de 94.09%, los segundos mejores resultados pertenecen a el modelo *SVM* con un *accuracy* medio de 90.18%, y por último está el modelo *KNN* el cual tuvo un *accuracy* medio de 80.90%. En base a los resultados, se seleccionó el modelo *RF* por el mejor desempeño, ya que obtuvo los mejores valores medios de *accuracy*, *f1-score*, *recall* y *precisión*, además, generó subconjuntos de hasta 95.45% de *accuracy*.

La principal fortaleza del modelo de *RF* radica en su capacidad para crear múltiples árboles con diferentes descriptores. En *RF*, los descriptores seleccionados para cada árbol son elegidos de manera aleatoria, lo que implica que los árboles no se profundizan y se centran únicamente en un subconjunto de descriptores. Esta característica permite que cada árbol se enfoque en un conjunto

específico de descriptores, evitando la redundancia y permitiendo una mayor diversidad en la selección de características utilizadas para la clasificación.

Al tener 817 descriptores, en su mayoría de color, es posible que existan muchos que sean redundantes si están correlacionados o si se evalúan todos juntos. Sin embargo, en *RF*, al dividirlos aleatoriamente en subconjuntos para cada árbol, se distribuyen de tal manera que cada árbol tiene información relevante para su clasificación individual, evitando relaciones anulatorias que podrían ocurrir al evaluar todos los descriptores juntos, como sucede en *SVM* y *KNN*. Por esta razón, *RF* es beneficioso para clasificaciones de este tipo, ya que una de sus ventajas es su capacidad para manejar mayor dimensionalidad de variables de entrada e identificar las variables más significativas. En comparación, *SVM* y *KNN* pueden tener limitaciones en la presencia de un alto número de descriptores de entrada. Además, *RF* es intrínsecamente adecuado para problemas multiclase, a diferencia de *SVM* que es intrínsecamente de dos clases.

Eliminación y Selección de Descriptores

El análisis realizado mediante *RFECV* reveló que el número ideal de descriptores para el algoritmo de *RF* es 323, como se muestra en las Figuras 4.5 y 4.6, donde se presenta el valor medio de precisión obtenido a través de la validación cruzada con $K=5$ *Folds*. Estos resultados respaldan la elección de este número de descriptores como óptimo para lograr un alto rendimiento del modelo. Es importante destacar que, a partir de los 130 descriptores, se observa una disminución en la precisión del modelo, lo que indica que utilizar 130 o menos descriptores no permitiría obtener el valor máximo de *accuracy* posible. Por lo tanto, es fundamental mantener una cantidad adecuada de descriptores en el modelo para asegurar su rendimiento óptimo.

Es interesante notar que, durante la selección de características, se eliminaron descriptores relacionados con el color, lo que destaca la importancia de los descriptores de textura, tamaño y forma en este contexto. Este hallazgo sugiere que los descriptores de textura, tamaño y forma son relevantes para la predicción del modelo, y que la eliminación de los descriptores de color no afecta negativamente el *accuracy*, ya que solo se eliminaron los descriptores de color redundantes. En resumen, los resultados obtenidos mediante la técnica de selección de características *RFECV*, respaldan la elección de 323 descriptores como el número óptimo para el algoritmo de *RF*, destacando la importancia de los descriptores de textura, tamaño y forma en la predicción del modelo.

Figura 4.5. *Gráfica de eliminación recursiva de descriptores*





Figura 4.6. *Zoom de gráfica de eliminación recursiva de descriptores*

Resultados Finales

Se llevó a cabo una rigurosa evaluación del modelo *RF* con base en la técnica de validación cruzada con $K=5$ *Folds* en una base de datos de 1100 imágenes. Como resultado, se identificaron los 323 descriptores óptimos para el algoritmo de *RF*, con los cuales se implementó el modelo utilizando exclusivamente estos descriptores. Los resultados detallados de esta evaluación se presentan en la Tabla 4.4, brindando una visión completa del desempeño del modelo y su capacidad para abordar la clasificación de defectos.

Tabla 4.4. Métricas de desempeño para *RF* con 323 descriptores

Subconjunto	Accuracy	Precision	Recall	F1-Score
1	0.9364	0.9353	0.9348	0.9347
2	0.9545	0.9512	0.9552	0.9526
3	0.9500	0.9512	0.9476	0.9486
4	0.9273	0.9328	0.9265	0.9277
5	0.9409	0.9465	0.9444	0.9434
Promedio	0.9418	0.9434	0.9417	0.9414

Se llevaron a cabo comparaciones de los valores promedio de las Tablas 4.3 y 4.4 en la Tabla 4.5, y se evaluó el desempeño del modelo utilizando 817 y 323 descriptores, respectivamente. Se observó una mejora en las métricas de desempeño, incluyendo un aumento del 0.0966% en el *accuracy*, un incremento del 0.1271% en la *precision*, un aumento del 0.1553% en el *recall* y un incremento del 0.1501% en el *f1-score*. Es importante destacar que esta mejora se logró a pesar de haber reducido 494 descriptores.

Es interesante notar que, a pesar de la reducción en el número de descriptores, las métricas de desempeño mejoraron levemente. De hecho, si se aproximan los resultados para ambos casos, los valores serían prácticamente iguales. Esto sugiere que los 494 descriptores eliminados no eran relevantes para el algoritmo y, en cambio, estaban aumentando el costo computacional sin mejorar significativamente el desempeño del modelo. En resumen, la eliminación de los descriptores irrelevantes condujo a una mejora en las métricas de desempeño, lo que indica que se logró una optimización del sistema, al reducir la complejidad innecesaria y mejorar la eficiencia computacional sin comprometer el desempeño.

Tabla 4.5. *Promedio de las métricas según el número de descriptores*

# Descriptores	$\overline{Accuracy}$	$\overline{Precision}$	\overline{Recall}	$\overline{F1\ Score}$
X=817	0.9409	0.9422	0.9402	0.9400
X=323	0.9418	0.9434	0.9417	0.9414
ΔX	0.00091	0.00119	0.00146	0.0014
Aumento	0.0966%	0.1271%	0.1553%	0.1501%

A partir de un subconjunto de datos de la Tabla 4.4, se generó una matriz de confusión que se representa en la Figura 4.7. Los resultados son altamente satisfactorios, con una clasificación precisa en todos los tipos de defectos evaluados. Se identificaron solamente 10 imágenes mal clasificadas, distribuidas entre los diferentes tipos de defectos y la categoría de "sano". Esto demuestra un alto nivel de precisión en la clasificación del modelo, con un accuracy del 95.45%.

En definitiva, la matriz de confusión obtenida muestra un desempeño destacado en la clasificación de los defectos analizados, con una mínima cantidad de imágenes mal clasificadas y

una alta *accuracy* en general. Estos resultados confirman la capacidad del modelo en la tarea de clasificación de defectos en el conjunto de datos evaluado.

Figura 4.7. *Matriz de confusión*

True Class	flotador	negro	inmaduro	vinagre	cereza	hongos	mordido	arrugado	sintrilla	broca	normal
	16	0	0	0	0	0	0	1	0	0	1
	0	20	0	0	0	0	0	0	0	0	0
	0	0	18	0	0	0	1	0	0	0	1
	0	0	0	20	0	0	0	0	0	0	0
	0	0	0	0	19	0	0	0	0	0	0
	0	0	1	0	0	14	1	1	0	0	0
	0	0	1	0	0	0	15	0	0	0	0
	1	0	0	0	0	0	0	21	0	0	0
	0	0	0	0	0	0	0	0	29	0	0
	0	0	0	0	0	0	0	0	0	24	0
	0	0	0	0	0	0	0	1	0	0	14
Predicted Class											

En la Tabla 4.6, se detallan las métricas de desempeño obtenidas mediante el análisis de la matriz de confusión, brindando una visión clara del desempeño del sistema clasificador. Por otro lado, en la Tabla 4.7 se presentan los resultados cuantitativos de la correcta clasificación de los granos por categoría, ofreciendo una perspectiva detallada de la eficiencia del modelo en cada una de las categorías evaluadas.

Tabla 4.6. *Métricas de desempeño*

Clases	Precision	Recall	F1-Score	# imágenes
Flotador	0.94	0.89	0.91	18
Negro	1	1	1	20
Inmaduro	0.9	0.9	0.9	20
Vinagre	1	1	1	20
Cereza	1	1	1	19
Hongos	1	0.82	0.9	17
Mordido/Partido	0.88	0.94	0.91	16
Arrugado	0.88	0.95	0.91	22
Pergamino	1	1	1	29
Broca	1	1	1	24
Sano/Normal	0.88	0.93	0.9	15
Total				220
Accuracy				95.45%

Tabla 4.7. *Clasificación de los granos por categoría*

Clasificación	Categoría 1	Categoría 2
Correcta	97	99
Errado	3	6
Total	100	105

Al examinar la Tabla 4.6, la matriz de confusión y las métricas de desempeño, es importante tener en cuenta que el *f1-score* es el promedio armónico de la *precision* y el *recall*,

alcanza su valor máximo en 1, lo cual representa una *precision* y *recall* perfectos. Por el contrario, su valor mínimo es 0. Por lo tanto, en el análisis general de la matriz de confusión, además de evaluar *el recall*, *presicion* y *accuracy*, se dará una atención especial al *f1-score* como indicador para evaluar el rendimiento general del modelo en estudio.

- El valor de *accuracy* alcanzó un 95.45%, lo que indica que el clasificador en general tuvo un alto desempeño, en donde solo un 4.55% de los datos fueron clasificados de manera incorrecta, lo cual evidencia que el modelo *RF* y los descriptores seleccionados lograron diferenciar y clasificar de manera efectiva todas las clases en su conjunto.
- El *f1-score* fue de 1 para 5 clases; Negro, vinagre, cereza, pergamino y broca, lo que significa que no hubo falsos positivos ni falsos negativos para cada una de estas clases. Por ende el 100% de las predicciones positivas para cada clase fue correcta, y todos los casos positivos fueron identificados correctamente por el algoritmo respecto a los casos reales positivos de cada clase. Este era un resultado esperado debido a que la tonalidad, forma, tamaño y textura de estas clases son homogéneas, además de la poca variabilidad entre granos de la misma clase de cada tipo de defecto. Esto hizo fácil su diferenciación, difícil confusión entre clases y la ausencia de falsos positivos y falsos negativos.
- Para las clases de Mordido/Partido, Arrugado y Sano/Normal se obtuvieron los valores más bajos de *precision*. Este resultado indica que hubo errores en la clasificación de algunos granos que pertenecen a estas clases, debido a su semejanza visual con granos de otras clases.
- En la clasificación, se identificó un caso en el que un grano flotador fue clasificado incorrectamente como arrugado, y viceversa. Esto pudo haber ocurrido debido a que los defectos de flotador y arrugado a veces presentan similitudes en su textura y tonalidad. Por

ejemplo, los granos flotadores pueden tener una apariencia ligeramente arrugada. Esta similitud pudo haber generado confusión en el algoritmo de clasificación en algunos casos, como se evidencia en la matriz de confusión.

- Se identificó un caso en el que un grano con hongo fue clasificado incorrectamente como grano mordido/cortado. Este tipo de error puede deberse al proceso al que los granos de ambos tipos de defectos son sometidos. En la mayoría de los granos de la clase mordido/partido, la oxidación del grano generada por ser cortado o mordido por las aspas de las máquinas puede resultar en tonalidades que van desde naranjas a rojizas, similares al color de la presencia del hongo en los granos de la clase hongo. Esto puede haber generado confusión en la clasificación, ya que el clasificador puede no distinguir con precisión en qué parte del grano se encuentran estas tonalidades, solo se sabe con seguridad que existen, pero no su ubicación exacta. Como resultado, este tipo de error puede ocurrir, al igual que la clasificación errónea de un grano mordido como uno con hongo, en función de la presencia de estas tonalidades.
- Se observó que un grano inmaduro y un grano flotador fueron clasificados erróneamente como granos normales. Esto puede deberse a las tonalidades similares al grano normal y a su textura. Algunos granos normales presentan una ligera membrana que confiere una textura similar a los defectos de flotador e inmaduro, lo que puede generar confusión en la clasificación. Es importante destacar que la clasificación errónea de cualquier tipo de defecto como grano sano es menos confiable y más perjudicial que la confusión entre otros tipos de defectos. Esto se debe a que, si se considera una evaluación basada en la normativa de la SCA y se clasifican granos con defectos como granos sanos, la muestra de café sería evaluada de manera incorrecta, lo que podría resultar en la determinación errónea de una

muestra como café de especialidad cuando en realidad no lo es. En contraste, en el caso de una confusión entre tipos de defectos, aunque también sea incorrecta, la clasificación de granos sanos seguiría siendo correcta, y aunque haya confusión entre defectos, estos seguirían contribuyendo a la generación de faltas en la muestra.

- De acuerdo con los defectos negro, vinagre, cereza seca y broca pertenecientes a la categoría 1 y con base en la Tabla 4.7, se observa que el algoritmo identificó y clasificó correctamente el 100% de los granos de estos defectos, demostrando alta fiabilidad de selección de 4 de los 5 tipos de defectos más influyentes a la hora de determinar si una muestra de café puede ser considerada café de especialidad o no.
- De acuerdo con los defectos pertenecientes a la categoría 2 (Tabla 2.1) y según el *recall*, se observa que el algoritmo identificó y clasificó el 100% de los granos pergamino, 95% de arrugados, 94% de mordidos/Partidos, 90% de inmaduros y 89% en los flotadores, demostrando alta fiabilidad ya que el *recall* promedio para los defectos de categoría 2 sería de aproximadamente del 94%, lo que significa que de 105 granos pertenecientes a la categoría 2, solo 6 se clasificaron mal, como se puede observar en la Tabla 4.7.
- En base a la muestra de 220 granos clasificados y suponiendo que estos forman parte de una muestra real de 350 granos, se podría inferir que se clasificaron correctamente 4 tipos de defectos de la categoría 1, lo cual proporcionaría el valor real de las faltas ocasionadas por esos defectos. En el caso de la categoría 2, solo el tipo de defecto "pergamino" evidenciaría faltas reales. Sin embargo, al examinar la Tabla 4.7, se observa que hubo 9 granos mal clasificados de otros tipos de defectos, además del grano mal clasificado perteneciente a la clase "sano/normal". Estos errores de clasificación podrían generar un aumento de faltas no verdaderas, al atribuirse incorrectamente a tipos de defectos a los que

se les asignó un grano equivocado. Aunque la cantidad de granos mal clasificados es baja, esto podría tener una leve repercusión en el origen y la contabilidad de las faltas.

Conclusiones

Durante la realización de esta investigación se analizaron datos y confrontaron resultados, a partir de los cuales se llegaron a las siguientes conclusiones:

- Se logró desarrollar un algoritmo que superó las expectativas de Tecnicafé, al alcanzar un nivel de *accuracy* del 94.18% en la clasificación de 11 clases, incluyendo 10 tipos de defectos y el tipo de grano sano. Este resultado evidencia una gran relevancia, ya que en este trabajo ha sido posible optimizar la clasificación y minimizar los errores inherentes a la subjetividad del evaluador-observador, lo cual tendría un impacto significativo en la eficiencia de la producción y en la mejora de la calidad del café.
- En este trabajo, se ha determinado que las características relacionadas con el color son de gran relevancia en la clasificación de defectos, ya que la mayoría de estos se distinguen por sus tonalidades. Por lo tanto, se utilizó un alto porcentaje de características basadas en el color, representando aproximadamente el 98% del total de características empleadas en el proceso de clasificación. Esto resalta la importancia del color como un factor clave en la identificación precisa de defectos en el café.
- La calidad del proceso de captura de imágenes es crucial, ya que un adecuado desarrollo bajo las mejores condiciones posibles resultará en un ahorro de tiempo y esfuerzo durante el posterior proceso de pre-procesamiento de las imágenes. En este estudio, se logró realizar la captura de imágenes en un ambiente controlado, lo cual garantizó un alto *accuracy* en los resultados obtenidos.
- Las métricas de desempeño utilizadas en este trabajo han proporcionado una evaluación detallada del rendimiento de los clasificadores. El uso del *accuracy* permitió tener una idea general, mientras que la aplicación de *precision*, *recall* y *f1-score* reveló detalles

específicos del desempeño de las clases individualmente, lo que demostró ser efectivo para evaluar los clasificadores desde diversas perspectivas.

- La experiencia y asesoramiento del equipo de expertos de Tecnicafé fueron fundamentales en la identificación y selección de defectos en el proceso de clasificación de los granos de café. Gracias a su conocimiento, se pudo crear una base de datos confiable asegurando la calidad y confiabilidad de los datos utilizados.

Bibliografía

- Betancourt, G. A. (2005). Las máquinas de soporte vectorial (SVMs). *Scientia et technica*, 1(27).
- Berrar, D. (2019). Validación cruzada.
- Browne, MW (2000). Métodos de validación cruzada. *Revista de psicología matemática*, 44 (1), 108-132.
- Borrero Becerra, J. C., & Diaz Molano, C. A. Elaboración de base de datos de fotografías de granos de café seco con diferentes defectos físicos, caracterizados con métodos estándar de PDI y clasificación.
- Escalera Hueso, A. d. l. (2001). *Visión por computador: fundamentos y métodos*. Pearson Educación.
- Ferreira, A. J., & Figueiredo, M. A. (2012). Efficient feature selection filters for high dimensional data. *Pattern recognition letters*, 33(13), 1794-1804.
- García, Candelo-Becerra, & Hoyos. (2019). Quality and Defect Inspection of Green Coffee Beans Using a Computer Vision System. *Applied Sciences*, 9(19), 4195. doi:10.3390/app9194195
- Guido, S., & Mueller, A. C. (2016). *Introduction to machine learning with python*. Sebastopol, CA: O'Reilly Media.
- Hall, M. A. (1999). *Correlation-based feature selection for machine learning* (Tesis doctoral, The University of Waikato).
- Hoyos Garcia, J. (n.d.). *TECNiCAFE - Parque Tecnológico de Innovación del Café*. Recuperado Marzo 19, 2023, from <https://tecnicafe.co/>

- Huang, N.-F., Chou, D.-L., Lee, C.-A., Wu, F.-P., Chuang, A.-C., Chen, Y.-H. y Tsai, Y.-C. (2020), Agricultura inteligente: clasificación en tiempo real de granos de café verde mediante el uso de una red neuronal convolucional. *IET Ciudades Inteligentes*, 2: 167-172.
- Janandi, R., & Cenggoro, T. W. (2020). An Implementation of Convolutional Neural Network for Coffee Beans Quality Classification in a Mobile Information System. 2020 International Conference on Information Management and Technology (ICIMTech).
- Osorio, V. (2021). La calidad del Café. En Centro Nacional de Investigaciones de Café, Guía más agronomía, más productividad, más calidad (3a ed., pp. 219–234). Cenicafé.
- Pabón, J., & Osorio, V. (2019). Factores e indicadores de la calidad física, sensorial y Química del café. En Centro Nacional de Investigaciones de Café (Ed.), *Aplicación de ciencia tecnología e innovación en el cultivo del café ajustado a las condiciones particulares del Huila* (págs. 162–187). Cenicafé.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Pérez, M. A. A. (2009). Espacios de Color RGB, HSI y sus Generalizaciones a n-Dimensiones. INAOE, Tonantzintla.
- Pinto, C., Furukawa, J., Fukai, H., & Tamura, S. (2017). Classification of Green coffee bean images basec on defect types using convolutional neural network (CNN). 2017 International Conference on Advanced Informatics, Concepts, Theory, and Applications (ICAICTA).

- Pizzaia, J. P. L., Salcides, I. R., Almeida, G. M. de, Contarato, R., & Almeida, R. de. (2018). Arabica coffee samples classification using a Multilayer Perceptron neural network. 2018 13th IEEE International Conference on Industry Applications (INDUSCON).
- Portugal-Zambrano, C. E., Gutierrez-Caceres, J. C., Ramirez-Ticona, J., & Beltran-Castanon, C. A. (2016). Computer vision grading system for physical quality evaluation of green coffee beans. 2016 XLII Latin American Computing Conference (CLEI). doi:10.1109/clei.2016.7833383
- Puerta, G. I. (2015). Buenas prácticas para la prevención de los defectos de la calidad del café: Fermento reposado fenólico y mohoso. Centro Nacional de Investigaciones de Café (Cenicafé).
- Roa, G., Oliveros, C. E., Álvarez, J., Ramírez, C. A., Sanz, J. R., Dávila, M. T., ... & Rodríguez, N. (1999). Beneficio ecológico del café.
- Santos, F. F. L. D., Rosas, J. T. F., Martins, R. N., Araújo, G. D. M., Viana, L. D. A., & Gonçalves, J. D. P. (2020). Quality assessment of coffee beans through computer vision and machine learning algorithms.
- SCA — Specialty Coffee Association. (n.d.). Specialty Coffee Association. Recuperado marzo 1, 2023, de <https://sca.coffee/about>
- Specialty Coffee Association. (2019). El café Arábica lavado Guía de defectos del café verde. Recuperado de https://bootcoffee.com/wp-content/uploads/2019/09/SCA_The-Arabica-Green-Coffee-Defect-Guide_Spanish_updated.pdf.

Bibliografía de imágenes

Wikimedia Commons. (12 de enero de 2008). *Wikimedia Commons*. Obtenido de

https://commons.wikimedia.org/wiki/File:RGB_color_solid_cube.png

Wikipedia. (5 de agosto de 2022). *Wikipedia*. Obtenido de Wikipedia:

https://es.wikipedia.org/wiki/Modelo_de_color_HSL

Wikipedia. (17 de Marzo de 2023). *Wikipedia*. Obtenido de Wikipedia:

<https://es.wikipedia.org/wiki/YCbCr#:~:text=YCbCr%2C%20tambi%C3%A9n%20conocido%20como%20Y,y%20diferencia%20de%20rojo%2C%20respectivamente.>

Wikipedia. (13 de Marzo de 2023). *Wikipedia*. Obtenido de Wikipedia:

https://es.wikipedia.org/wiki/Espacio_de_color_CIE_1931

